

Théories de l'estimation indirecte et sur petits domaines : fondements épistémologiques et débats contemporains

Introduction

La problématique de l'estimation sur petits domaines (Small Area Estimation - SAE) constitue l'un des défis méthodologiques les plus complexes de la statistique appliquée contemporaine. Formalisée initialement par Fay et Herriot (1979) dans leur travail séminal sur l'estimation du revenu par comté aux États-Unis, cette approche répond à une demande croissante d'indicateurs statistiques désagrégés géographiquement, particulièrement prégnante dans le contexte des politiques publiques ciblées (Rao & Molina, 2015). La tension fondamentale entre précision statistique et granularité géographique que soulève cette problématique a donné naissance à un corpus théorique riche, marqué par des débats épistémologiques profonds sur les fondements de l'inférence statistique.

Dans le contexte spécifique de la mesure de la pauvreté multidimensionnelle, ces enjeux théoriques revêtent une dimension particulière. Les travaux pionniers d'Elbers, Lanjouw et Lanjouw (2003) sur la cartographie de la pauvreté ont ouvert la voie à une littérature extensive, mais ont également cristallisé des controverses méthodologiques majeures, notamment autour de la validité des hypothèses de stationnarité spatiale et temporelle (Tarozzi & Deaton, 2009). Cette revue propose une analyse critique des fondements théoriques de ces approches, en portant une attention particulière aux débats fréquentiste-bayésien qui traversent ce champ disciplinaire.

1. Genèse et fondements épistémologiques

1.1 Émergence historique et contexte institutionnel

L'estimation sur petits domaines trouve ses racines dans les besoins institutionnels des bureaux de statistiques nationaux confrontés à la demande croissante d'indicateurs localisés. Le modèle fondateur de Fay et Herriot (1979), développé pour le Bureau du Recensement américain, établit le cadre conceptuel de référence en formalisant le compromis entre information directe limitée et modélisation statistique. Cette approche pragmatique, motivée par des contraintes opérationnelles plutôt que par des considérations théoriques pures, a néanmoins posé les jalons d'une révolution méthodologique dont les implications dépassent largement le cadre initial.

L'extension de ce paradigme aux pays en développement, impulsée notamment par les travaux de la Banque mondiale dans les années 1990, a révélé de nouveaux défis théoriques. Hentschel et al. (2000) ont souligné les spécificités des contextes de données limitées, caractérisés par une hétérogénéité spatiale plus marquée et des structures socio-économiques plus complexes que dans les pays développés. Cette transposition a alimenté un débat sur l'universalité des méthodes statistiques et la nécessité d'adaptations contextuelles.

1.2 Formalisation du problème fondamental

La problématique centrale de l'estimation sur petits domaines peut être formalisée comme un problème d'optimisation sous contrainte. Soit θ_i le paramètre d'intérêt pour le domaine i , et $\hat{\theta}_i^{\text{direct}}$ l'estimateur direct basé sur l'échantillon n_i . Le dilemme fondamental réside dans l'arbitrage entre :

- La non-biaisé de l'estimateur direct : $E[\hat{\theta}_i^{\text{direct}}] = \theta_i$
- Sa variance élevée : $\text{Var}(\hat{\theta}_i^{\text{direct}}) = \sigma^2/n_i$, prohibitive lorsque n_i est faible

Ce trade-off biais-variance, bien qu'ancré dans la théorie statistique classique, soulève des questions épistémologiques profondes sur la nature de la "vérité" statistique et les critères d'optimalité en présence d'information limitée. Jiang et Lahiri (2006) ont formalisé cette tension à travers la décomposition de l'erreur quadratique moyenne, établissant les conditions théoriques sous lesquelles l'introduction d'un biais par la modélisation peut être justifiée par la réduction de variance obtenue.

1.3 Paradigmes concurrents et clivages théoriques

L'évolution de la littérature SAE a été marquée par l'émergence de deux paradigmes concurrents, reflétant des conceptions divergentes de l'inférence statistique. Le paradigme fréquentiste, dominant dans les développements initiaux, conçoit l'estimation comme la recherche d'estimateurs aux propriétés optimales dans l'espace des échantillons possibles. À l'inverse, le paradigme bayésien, dont l'influence s'est accrue depuis les années 1990, privilégie une approche probabiliste intégrant explicitement l'incertitude sur les paramètres inconnus.

Cette dichotomie, loin d'être purement technique, reflète des visions philosophiques distinctes de la connaissance statistique et de sa finalité dans l'aide à la décision publique.

2. Modélisation fréquentiste : développements et limites

2.1 L'approche synthétique : simplicité et robustesse

Les méthodes de régression synthétique, développées initialement par Hansen, Hurwitz et Madow (1953), constituent l'approche la plus directe pour l'estimation sur petits domaines. Le principe consiste à estimer un modèle de régression sur l'échantillon global :

$$y_{ij} = x_{ij}^T \beta + \varepsilon_{ij}$$

puis à prédire pour chaque domaine : $\hat{\theta}_i^{\text{synth}} = \bar{x}_i^T \hat{\beta}$

Cette approche présente l'avantage de la simplicité conceptuelle et de la robustesse computationnelle. Gonzalez et Waksberg (1973) ont démontré sa convergence sous des conditions de régularité standard. Cependant, les travaux de Purcell et Kish (1980) ont mis en évidence une limitation fondamentale : l'ignorance de la variabilité inter-domaines peut conduire à une sous-estimation systématique de l'incertitude, compromettant la validité des intervalles de confiance.

2.2 Révolution des modèles mixtes : l'estimateur EBLUP

L'introduction des modèles à effets mixtes par Henderson (1950), puis leur adaptation aux petits domaines par Battese, Harter et Fuller (1988), a marqué une rupture méthodologique majeure. Le modèle de référence :

$$y_i = x_i^T \beta + v_i + e_i$$

où $v_i \sim N(0, \sigma_v^2)$ représente l'effet aléatoire spécifique au domaine, permet de concilier élégamment l'information directe et l'information modélisée à travers l'estimateur EBLUP (Empirical Best Linear Unbiased Predictor) :

$$\hat{\theta}_i^{\text{EBLUP}} = \gamma_i \hat{\theta}_i^{\text{direct}} + (1-\gamma_i) x_i^T \hat{\beta}$$

Le facteur de rétrécissement $\gamma_i = \sigma_v^2 / (\sigma_v^2 + \psi_i)$ formalise mathématiquement l'intuition statistique : plus l'information directe est fiable (ψ_i faible), plus le poids accordé à cette source est important.

Prasad et Rao (1990) ont établi les propriétés asymptotiques de cet estimateur, démontrant notamment sa convergence vers le BLUP théorique sous des conditions de régularité. Cependant, Kackar et Harville (1984) ont souligné une subtilité conceptuelle importante : l'estimateur EBLUP n'est plus strictement non-biaisé en raison de l'estimation des composantes de variance, introduisant un biais d'ordre $O(1/m)$ où m est le nombre de domaines.

2.3 Critiques et limitations de l'approche fréquentiste

Malgré ses fondements théoriques solides, l'approche fréquentiste fait l'objet de critiques substantielles. Datta et Lahiri (2000) ont questionné la validité des approximations asymptotiques dans les échantillons de taille finie typiques des applications, démontrant que les intervalles de confiance peuvent présenter des taux de couverture significativement différents du niveau nominal.

Plus fondamentalement, Carlin et Louis (1996) ont souligné les difficultés conceptuelles liées au traitement des composantes de variance comme paramètres fixes alors qu'elles sont estimées avec incertitude. Cette critique touche au cœur du paradigme fréquentiste et de sa capacité à gérer l'incertitude sur les paramètres de nuisance.

3. Paradigme bayésien : naturalité conceptuelle et défis pratiques

3.1 Fondements théoriques et avantages conceptuels

L'approche bayésienne, formalisée dans le contexte SAE par Ghosh et Rao (1994), offre un cadre théorique naturel pour l'intégration de sources d'information multiples. La modélisation hiérarchique à trois niveaux :

- Niveau observation : $y_i | \theta_i, \varphi \sim f(\theta_i, \varphi)$
- Niveau domaine : $\theta_i | \mu, \tau^2 \sim N(\mu, \tau^2)$
- Niveau hyperparamètres : $p(\mu, \tau^2)$

permet une propagation cohérente de l'incertitude à travers tous les niveaux hiérarchiques. Cette approche présente plusieurs avantages conceptuels par rapport au paradigme fréquentiste.

Premièrement, l'incertitude sur les paramètres est traitée de manière unifiée à travers la distribution a posteriori, éliminant les difficultés conceptuelles liées aux paramètres de nuisance. Deuxièmement, l'incorporation d'information a priori permet d'intégrer explicitement la connaissance experte ou les résultats d'études antérieures. Troisièmement, la prédiction probabiliste est naturellement définie par la distribution prédictive a posteriori.

3.2 Spécification des distributions a priori : débats et controverses

La spécification des distributions a priori constitue l'un des aspects les plus controversés de l'approche bayésienne. Kass et Wasserman (1996) distinguent trois types d'approches :

Priors informatifs : Basés sur la connaissance a priori substantielle, ils permettent d'améliorer significativement l'efficacité des estimateurs. Cependant, leur spécification soulève des questions de subjectivité et de reproductibilité scientifique.

Priors non-informatifs : Les priors de Jeffreys ou de référence visent à minimiser l'influence de l'information a priori. Toutefois, Berger et Bernardo (1992) ont démontré que le choix d'un prior "objectif" reste fondamentalement arbitraire et peut avoir des conséquences substantielles sur les résultats.

Priors hiérarchiques : L'utilisation de hyperpriors permet de réduire l'influence des spécifications particulières, mais au prix d'une complexité computationnelle accrue et de potentielles difficultés d'identification.

Cette problématique est particulièrement aiguë dans le contexte des petits domaines où l'information limitée rend les résultats potentiellement sensibles aux spécifications a priori. Daniels (1999) a démontré que des priors apparemment non-informatifs peuvent avoir des effets substantiels sur les estimations finales.

3.3 Révolution computationnelle et MCMC

L'avènement des méthodes de Monte Carlo par chaînes de Markov (MCMC) dans les années 1990 a révolutionné la praticabilité des approches bayésiennes. Gelfand et Smith (1990) ont démontré que l'échantillonnage de Gibbs permet de générer des échantillons de la distribution a posteriori sans recourir à l'intégration analytique, ouvrant la voie à des modèles de complexité arbitraire.

Dans le contexte SAE, cette révolution computationnelle a permis le développement de modèles spatiaux sophistiqués, intégrant notamment l'autocorrélation géographique à travers des modèles conditionnels autorégessifs (CAR). Besag, York et Mollié (1991) ont proposé le modèle BYM, devenu référence pour la modélisation spatiale bayésienne :

$$V_i = U_i + S_i$$

où u_i suit une distribution CAR capturant la corrélation spatiale structurée, et $s_i \sim N(0, \tau_s^2)$ représente l'hétérogénéité non-structurée.

3.4 Défis contemporains et limites

Malgré ses avantages conceptuels, l'approche bayésienne fait face à plusieurs défis contemporains. La convergence des algorithmes MCMC, particulièrement dans les modèles hiérarchiques complexes, reste un enjeu technique majeur. Brooks et Gelman (1998) ont développé des diagnostics de convergence, mais leur interprétation demeure délicate en pratique.

Plus fondamentalement, Sims (2007) a questionné la capacité des méthodes bayésiennes à gérer efficacement les problèmes de grande dimension typiques des applications contemporaines. Cette critique a motivé le développement d'approximations alternatives, notamment les méthodes variationnelles et l'approximation de Laplace imbriquée intégrée (INLA) proposée par Rue, Martino et Chopin (2009).

4. Débats méthodologiques contemporains

4.1 Validation et évaluation des performances

L'évaluation des méthodes SAE soulève des défis méthodologiques spécifiques liés à l'absence de "vérité terrain" pour les petits domaines. Trois approches principales ont émergé dans la littérature :

Validation croisée : Brown et al. (2001) ont proposé une approche de validation croisée spatialement structurée, excluant successivement des domaines de l'estimation. Cette méthode permet d'évaluer la capacité prédictive des modèles, mais sa validité repose sur l'hypothèse de stabilité des relations modélisées.

Simulation Monte Carlo : L'utilisation de populations synthétiques permet une évaluation contrôlée des performances, mais soulève des questions de réalisme des modèles de données générés. Tzavidis et al. (2018) ont développé des protocoles de simulation basés sur des données réelles pour améliorer le réalisme de ces évaluations.

Benchmarking : La comparaison avec des sources externes (recensements, enquêtes spécifiques) constitue l'étalon-or, mais reste limitée par la disponibilité et la comparabilité de ces sources de référence.

4.2 Robustesse et diagnostics de modèle

La question de la robustesse des méthodes SAE face aux violations des hypothèses de modélisation constitue un enjeu théorique central. Chambers et al. (2014) ont développé des approches semi-paramétriques visant à réduire la dépendance aux hypothèses distributionnelles, tandis que Salvati et al. (2012) ont proposé des extensions robustes des estimateurs EBLUP résistantes aux valeurs aberrantes.

Le développement de diagnostics de modèle adaptés aux contextes SAE reste un défi ouvert. Les diagnostics classiques (résidus, Q-Q plots) sont peu informatifs dans le contexte de petits échantillons,

nécessitant le développement d'outils spécialisés. Marshall et Spiegelhalter (2003) ont proposé des extensions bayésiennes des diagnostics classiques, mais leur interprétation demeure complexe.

4.3 Intégration de sources de données multiples

L'avènement du Big Data a ouvert de nouvelles perspectives pour l'estimation sur petits domaines, mais a également soulevé de nouveaux défis théoriques. L'intégration de données d'enquête traditionnelles avec des sources non-probabilistes (données administratives, images satellitaires, données de téléphonie mobile) nécessite le développement de nouveaux cadres théoriques.

Deville et Särndal (2007) ont proposé une approche basée sur l'étalonnage généralisé, mais l'extension aux contextes multisources reste problématique. Les travaux récents de Chen et al. (2020) sur l'intégration bayésienne de sources hétérogènes ouvrent des perspectives prometteuses, mais soulèvent des questions de cohérence et d'identifiabilité.

5. Applications spécifiques à la pauvreté multidimensionnelle

5.1 Défis méthodologiques particuliers

La mesure de la pauvreté multidimensionnelle, formalisée par Alkire et Foster (2011), présente des spécificités qui complexifient l'application des méthodes SAE standard. L'indice de pauvreté multidimensionnelle (IPM), défini comme $IPM = H \times A$ où H représente l'incidence et A l'intensité de la pauvreté, présente plusieurs caractéristiques problématiques :

Distribution non-normale : La nature composite de l'indice génère des distributions asymétriques et bornées, violant les hypothèses de normalité des modèles classiques.

Corrélations complexes : Les interdépendances entre dimensions de pauvreté créent des structures de corrélation non-linéaires difficiles à modéliser.

Sensibilité aux seuils : La définition de seuils de privation introduit une discontinuité artificielle qui peut affecter la stabilité des estimations.

5.2 Adaptations méthodologiques

Plusieurs adaptations ont été proposées pour traiter ces spécificités. Pratesi et Salvati (2008) ont développé des extensions des modèles EBLUP pour les variables bornées, utilisant des transformations logit pour normaliser les distributions. Cette approche, bien que techniquement élégante, soulève des questions d'interprétabilité et de cohérence des transformations inverses.

L'approche bayésienne offre une flexibilité supérieure pour la modélisation de distributions non-standard. Nandram et Choi (2010) ont proposé des modèles beta-binomiaux pour les proportions bornées, tandis que Hobza et Morales (2016) ont développé des extensions pour les indices composites.

5.3 Cohérence spatiale et temporelle

La mesure de pauvreté soulève des exigences particulières de cohérence spatiale et temporelle. Les

estimations doivent respecter certaines contraintes logiques :

Cohérence d'agrégation : La somme pondérée des estimations de domaines doit être cohérente avec l'estimation nationale.

Continuité spatiale : Les estimations de domaines adjacents ne doivent pas présenter de discontinuités inexplicables.

Stabilité temporelle : L'évolution des estimations doit refléter des changements plausibles des conditions socio-économiques.

Ces contraintes nécessitent le développement de méthodes d'estimation sous contraintes, domaine encore peu exploré dans la littérature SAE. Zhang et Chambers (2004) ont proposé des approches de calibration, mais leur extension aux contextes multidimensionnels reste problématique.

6. Perspectives contemporaines et défis futurs

6.1 Intelligence artificielle et apprentissage automatique

L'intégration des méthodes d'apprentissage automatique dans le paradigme SAE constitue une frontière de recherche active. Les approches hybrides combinant machine learning et modélisation statistique offrent des perspectives prometteuses pour gérer la complexité croissante des données contemporaines.

D'Orazio (2021) a proposé l'utilisation de forêts aléatoires pour la sélection de variables dans les modèles SAE, démontrant des gains substantiels de performance prédictive. Cependant, cette approche soulève des questions théoriques importantes sur l'inférence et la quantification d'incertitude dans les modèles hybrides.

Les réseaux de neurones, particulièrement les architectures convolutionnelles pour l'analyse d'images satellitaires, ouvrent de nouvelles possibilités pour l'estimation de pauvreté. Tingzon et al. (2019) ont démontré la faisabilité de cette approche, mais les défis d'interprétabilité et de généralisation restent substantiels.

6.2 Défis computationnels et scalabilité

La croissance exponentielle du volume de données disponibles pose des défis computationnels inédits aux méthodes SAE traditionnelles. L'estimation bayésienne par MCMC devient prohibitive pour des applications à grande échelle, nécessitant le développement d'alternatives computationnellement efficaces.

L'approximation de Laplace intégrée imbriquée (INLA), développée par Rue et al. (2009), représente une avancée majeure en permettant l'approximation rapide de distributions a posteriori complexes. Son extension aux modèles SAE spatio-temporels de grande dimension fait l'objet de recherches actives.

Les méthodes variationnelles, empruntées à l'apprentissage automatique, offrent une alternative prometteuse pour l'approximation de distributions a posteriori. Blei, Kucukelbir et McAuliffe (2017) ont

démontré leur efficacité computationnelle, mais leur précision dans les contextes SAE reste à évaluer systématiquement.

6.3 Implications pour les politiques publiques

Au-delà des considérations techniques, l'évolution des méthodes SAE soulève des questions importantes sur leur utilisation dans l'élaboration des politiques publiques. La complexification croissante des méthodes crée une opacité qui peut compromettre l'appropriation par les décideurs et la légitimité démocratique des politiques basées sur ces estimations.

Cette tension entre sophistication technique et transparence démocratique nécessite le développement d'approches d'interprétabilité spécifiquement adaptées aux contextes SAE. Les méthodes d'explication locale (LIME, SHAP) développées en apprentissage automatique pourraient être adaptées à ces fins.

Conclusion et synthèse critique

Cette revue de la littérature révèle la richesse et la complexité des débats théoriques qui traversent le champ de l'estimation sur petits domaines. L'opposition traditionnelle entre paradigmes fréquentiste et bayésien, loin d'être purement technique, reflète des conceptions fondamentalement différentes de la connaissance statistique et de sa finalité dans l'aide à la décision.

L'approche fréquentiste, ancrée dans une tradition de robustesse et de propriétés asymptotiques établies, continue de dominer les applications opérationnelles en raison de sa simplicité conceptuelle et de sa acceptabilité institutionnelle. Cependant, ses limitations dans le traitement de l'incertitude sur les paramètres de nuisance et sa rigidité face aux structures de données complexes limitent son potentiel d'innovation.

L'approche bayésienne, malgré ses avantages conceptuels indéniables, fait face à des défis pratiques substantiels liés à la spécification des priors et à la complexité computationnelle. Son adoption croissante, facilitée par les développements algorithmiques récents, témoigne néanmoins de sa pertinence pour les applications contemporaines.

L'émergence de méthodes hybrides intégrant apprentissage automatique et modélisation statistique ouvre des perspectives prometteuses, mais soulève de nouveaux défis théoriques sur l'inférence et la quantification d'incertitude. Cette évolution nécessite un renouvellement des fondements théoriques de l'estimation sur petits domaines, réconciliant performance prédictive et rigueur inferentielle.

Dans le contexte spécifique de la mesure de pauvreté multidimensionnelle au niveau départemental au Sénégal, ces débats théoriques prennent une dimension particulière. L'hétérogénéité socio-économique et géographique du pays, combinée aux contraintes de données typiques des contextes africains, nécessite des adaptations méthodologiques spécifiques qui restent largement à développer. La synthèse de ces différentes approches théoriques constitue ainsi un préalable indispensable au développement d'une méthodologie adaptée aux spécificités sénégalaises.