



Organisation des Nations Unies
pour l'alimentation
et l'agriculture

Estimation sur petits domaines : modèles au niveau de l'unité



**Formation virtuelle 2022 sur la ventilation des données et l'estimation sur petits domaines
pour les ODD –**

22-25 novembre 2022, INStAD Bénin, INSTAT Mali, Stats South Africa, Statistics Botswana

BIENVENUE DANS LE MODULE 3 !

Jour 1 : Introduction


Jour 2 : Séances pratiques d'utilisation de R et EPD au niveau du domaine

Jour 3 : Séances pratiques d'utilisation de R et EPD au niveau de l'unité

- Pratiques : Exemples pratiques d'estimation sur petits domaines au niveau du domaine avec R
- Théorie : Introduction aux modèles d'EPD au niveau de l'unité

Jour 4 : Séances pratiques d'utilisation de R et présentations des pays





Modèles au niveau de l'unité : Introduction

L'estimation sur petits domaines à l'aide de modèles au niveau de l'unité :

- Présume de la disponibilité de données auxiliaires spécifiques aux unités $x_{ij} = (x_{ij1}, \dots, x_{ijp})^T$ pour chaque élément de population j et dans chaque petit domaine i .

Principales caractéristiques :

- Les méthodes au niveau de l'unité **permettent de produire des estimations présentant une EQM moindre** par rapport aux résultats obtenus grâce aux estimateurs directs, mais aussi par rapport à ceux obtenus grâce à des méthodes au niveau du domaine (en presumant que le modèle est correct).
- Tout comme les méthodes au niveau du domaine, **les modèles au niveau de l'unité tiennent compte de l'hétérogénéité inexpliquée entre les domaines** et permettent de produire des estimations pour les domaines non échantillonnés
- L'estimateur peut être vu comme une moyenne pondérée entre l'estimateur par la régression de l'enquête et un élément synthétique de régression. Le **poids** assigné à l'élément de régression de l'enquête **augmente avec la taille de l'échantillon**
- Contrairement aux méthodes au niveau du domaine, les poids d'échantillonnage ne sont pas pris en compte. Par ailleurs, les exigences en matière de données liées aux méthodes au niveau de l'unité sont plus strictes : les informations supplémentaires doivent être disponibles pour toutes les unités de la population, et les variables auxiliaires doivent partager la même définition.



RÉCAPITULATIF SUR L'ESTIMATEUR PAR LA RÉGRESSION GÉNÉRALISÉE

L'estimateur GREG de la moyenne pour l'estimation par domaine

Notation :

- Données : $\{y_{ij}, x_{ij}\}$, où j est la j^e unité dans l'échantillon S , et où i est l' i^e petit domaine
- $X_i = (X_{i1}, \dots, X_{ip})^T$ totaux de population (connus) pour les variables auxiliaires dans le petit domaine i
- Estimateur par la régression généralisée :

$$\hat{Y}_{i,GR} = \hat{Y}_i + (\bar{X}_i - \hat{X}_i)^T \hat{\beta}_i$$

- $\hat{\beta}_i = (\sum_{j \in S_i} w_{ij} x_{ij} x_{ij}^T / c_{ij})^{-1} (\sum_{j \in S_i} w_{ij} x_{ij} y_{ij} / c_{ij})$ où c_{ij} est une constante positive définie

L'estimateur GREG pour l'estimation par domaine

Principales caractéristiques :

- Les **estimateurs GREG** tentent d'améliorer la précision de l'estimateur HT traditionnel en empruntant les forces de variables auxiliaires pertinentes par l'ajustement des poids d'échantillonnage initiaux.
- Cet estimateur est encore approximativement sans biais par rapport au plan, et devrait permettre de réduire la variance d'échantillonnage et, ainsi, l'EQM générale.



MODÈLE D'EPD DE BASE AU NIVEAU DE L'UNITÉ

Méthode fondée sur un modèle – niveau des unités

Méthodes au niveau de l'unité pour les moyennes et les totaux :

- Modèles très populaires dans la **cartographie de la pauvreté**, l'une des applications les plus communes pour l'EPD
- **L'existence de données au niveau de l'unité est présumée** : la variable d'intérêt (p. ex., revenu du ménage, quantité produite totale, etc.) est contenue dans les données de l'enquête, et des variables auxiliaires avec un pouvoir prédictif sont disponibles dans les données d'enquête au niveau de l'unité. Ces mêmes variables auxiliaires doivent également être disponibles comme moyennes de domaine à partir d'une source de données supplémentaire non affectée par l'erreur d'échantillonnage.
- **Généralement préférables lorsqu'il existe des données au niveau de l'unité**. Contrairement aux méthodes au niveau du domaine, ce type de modèle ne tient pas compte du plan d'échantillonnage.

EBLUP avec méthode au niveau de l'unité

Le cadre sous-jacent est le même que d'habitude :

- La population cible est séparée en **D domaines** : $\Omega = \bigcup_{i=1}^D \Omega_i$
- Ω_i ($i = 1, \dots, D$) est l' **i^{e} domaine** dont la taille de population équivaut à N_i
- Données d'échantillon disponibles sur la variable cible y , de telle façon que $\mathbf{y} = [\mathbf{y}'_s, \mathbf{y}'_o]$
- $\mathbf{y}_s$ est le vecteur des unités observées n , tandis que $\mathbf{y}_o$ est le vecteur des unités non échantillonnées $N - n$, où N correspond à la taille générale de la population cible.
- D paramètres d'intérêt à estimer θ_i ($i = 1, \dots, D$)
- X est la matrice $p \times N$ de variables auxiliaires présumées connues pour toutes les unités au sein de la population

EBLUP avec méthode au niveau de l'unité (2)

Modèle de base au niveau de l'unité – connu sous le nom de modèle de régression linéaire à erreurs emboîtées ou modèle BHF_:

$$y_{ij} = x_{ij}\beta + u_i + e_{ij}$$

Où la covariance de deux unités j et j' est la suivante :

$$\text{Cov}(y_{ij}, y_{i'j'}) = \begin{cases} \sigma_{u_0}^2 + \sigma_{e_0}^2 & \text{if } i = i' \text{ et } j = j' \\ \sigma_{u_0}^2 & \text{if } i = i' \text{ et } j \neq j' \\ 0 & \text{if } i \neq i' \text{ et } j \neq j' \end{cases}$$

Ainsi, les unités appartenant au même petit domaine sont présumées corrélées, tandis que les unités de différents petits domaines sont présumées indépendantes

Le modèle Battese, Harter et Fuller

$$y_{ij} = x_{ij}\beta + u_i + e_{ij}$$

HYPOTHÈSES :

- $u_i \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2)$
- $e_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma_e^2)$
- $x_{ij} = (x_{ij1}, \dots, x_{ijp})^T$ est un vecteur-colonne $p \times 1$ des covariables pour la j^e unité dans l' i^e domaine
- β peut être estimé avec la méthodes des MCG habituelle, c'est-à-dire

$$\hat{\beta} = \left[\sum_{i=1}^D \sum_{j=1}^{n_d} x_{dj} (x_{dj} - \gamma_d \bar{x}_d)^T \right]^{-1} \left[\sum_{d=1}^D \sum_{j=1}^{n_d} (x_{dj} - \gamma_d \bar{x}_d)^T y_{dj} \right]$$

Le modèle Battese, Harter et Fuller

Le **meilleur prédicteur linéaire sans biais empirique (EBLUP)** peut être exprimé comme une moyenne pondérée (ou une combinaison linéaire) de l'estimateur par la régression de l'enquête (GREG) et d'un élément synthétique de régression :

$$\hat{\theta}_i^{EBLUP} = \hat{\gamma}_i [\bar{y}_i + (\bar{X}_i^T \hat{\beta} - \bar{x}_i^T \hat{\beta})] + (1 - \hat{\gamma}_i) \bar{X}_i^T \hat{\beta}$$

- $\bar{y}_i$ est la moyenne de la variable d'intérêt dans l'échantillon
- $\bar{X}_i^T$ et $\bar{x}_i^T$ sont les moyennes des informations auxiliaires de l'enquête et la source de données supplémentaire
- $\hat{\beta}$ est le vecteur de paramètres de régression
- $\hat{\gamma}_i = \frac{\hat{\sigma}_u^2}{\hat{\sigma}_u^2 + \frac{\hat{\sigma}_e^2}{n_i}}$ est un poids mesurant la part de la variabilité entre domaines inexpliquée par rapport à la variabilité totale.

N.B. : lorsque la taille de l'échantillon augmente, le poids de l'estimateur par la régression de l'enquête augmente également

Le modèle Battese, Harter et Fuller (4)

Pour les populations finies avec des fractions d'échantillonnage non négligeables, $f_i = \frac{n_i}{N_i}$, l'EBLUP peut être exprimé comme suit :

$$\hat{\theta}_i^{EBLUP} = f_i \bar{y}_i + (\bar{X}_i - f_i \bar{x}_i)^T \hat{\beta} + (1 - f_i) [\hat{\gamma}_i (\bar{y}_i - \bar{x}_i^T \hat{\beta})]$$

L'étape suivant la production d'EPD consiste à en **évaluer l'EQM** grâce à un logiciel standard.

Récapitulatif sur le modèle BHF et les estimateurs EBLUP

- L'EBLUP au niveau de l'unité est un **estimateur fondé sur un modèle** qui peut être utilisé également lorsque seules les **valeurs moyennes de la population** des variables auxiliaires sont connues.
- Dans de nombreuses applications, l'EBLUP produit de meilleures performances que les estimateurs fondés sur le plan de sondage habituels en termes de **coefficient de variation** (les estimations affichent des intervalles de confiance plus restreints).
- Le **facteur de retrait** $\hat{\gamma}_i$ joue un rôle important pour trouver un équilibre entre l'**élément de régression de l'enquête** et l'**élément synthétique de régression**. Lorsque $\hat{\sigma}_u^2$ est petit, alors $\hat{\gamma}_i$ est lui aussi petit et, par conséquent, un poids plus important est assigné à la partie synthétique de régression de l'estimateur. Il en va de même pour les valeurs peu élevées de la taille de l'échantillon spécifique à un domaine n_d .

Récapitulatif sur le modèle BHF et les estimateurs EBLUP (2)

- L'estimateur résultant du **modèle BHF** n'est pas convergent sous le plan pour les plans d'enquête généraux, puisque l'estimateur par la régression de l'enquête ne tient pas compte des poids d'échantillonnage.
- Par ailleurs, l'**EBLUP** n'est pas non biaisé pour le modèle après conditionnement sur u_d , puisque cela impliquerait de présumer de coordonnées fixes à l'origine dans les différents domaines.

Récapitulatif sur le modèle BHF et les estimateurs EBLUP (3)

Principales limitations

- L'**hypothèse de normalité est nécessaire** tant pour les effets au niveau du domaine que pour les effets individuels. Toutefois, une analyse de sensibilité peut montrer que le modèle est robuste contre la non-normalité lorsque la symétrie de ces distributions est respectée.
- L'**EBLUP** n'est pas sans biais par rapport au plan, ce qui signifie qu'en cas de plan d'enquête complexe, les estimations peuvent être sujettes à un biais.
- L'extension de ce modèle n'est pas facile à mettre en œuvre, en raison de la complexité de la dérivation de l'EQM.

Certaines extensions du modèle de base au niveau de l'unité

Certaines extensions/améliorations de l'**EBLUP de base**

- Processus spatiaux (modèles CAR et SAR)
- Processus temporels
- Processus spatiotemporels
- Modèles binaires et de comptage
- Effets aléatoires multiples (p. ex., package R MIND)

C'est l'heure du quizz !



Question 1 – CHOIX MULTIPLES

Le modèle Battese, Harter et Fuller au niveau de l'unité

- A. Présume de la normalité uniquement pour les termes de l'erreur
- B. Est le modèle d'EPD le plus courant au niveau de l'unité
- C. Présume de la normalité des termes de l'erreur et des effets aléatoires
- D. Est appelé modèle de régression linéaire à erreurs emboîtées

Question 2 – CHOIX MULTIPLES

L'EBLUP résultant d'un modèle d'EPD au niveau de l'unité est :

- A. Une moyenne pondérée de l'estimateur par régression de l'enquête et de l'élément synthétique de régression
- B. Peut être considéré comme un estimateur composite fondé sur un modèle
- C. Est sans biais par rapport au plan
- D. Est un estimateur assisté par un modèle

Question 3 – CHOIX UNIQUE

Est-il possible de prédire le paramètre d'intérêt dans les domaines non échantillonnés à l'aide de modèles au niveau de l'unité ?

- A. Oui
- B. Non

Question 4 – CHOIX UNIQUE

Les informations auxiliaires au niveau du domaine peuvent-elles être incluses dans les modèles au niveau de l'unité ?

- A. Oui
- B. Non

Modèles au niveau de l'unité : extensions aux indicateurs non linéaires

Le modèle BHF n'appuie que l'estimation des moyennes et totaux

Les extensions adaptées, fondées sur le modèle de régression linéaire à erreurs emboîtées, permettent d'estimer des indicateurs non linéaires tels que des proportions

Les deux approches les plus populaires sont les suivantes :

- La **méthode ELL** ou méthode de la Banque mondiale
- Le **meilleur prédicteur empirique (EBP)**

Ces deux approches sont couramment utilisées pour procéder à une **cartographie de la pauvreté**

Modèles au niveau de l'unité : extensions aux indicateurs non linéaires

Idée générale sous-tendant ces extensions :

- Les données de l'enquête sont utilisées pour ajuster un modèle reliant la variable d'intérêt et les informations auxiliaires au niveau de l'unité, ce qui aboutit à des estimations de $\hat{\beta}$, $\hat{\sigma}_u^2$, $\hat{\sigma}_e^2$ des paramètres du modèle.
- La relation du modèle, les paramètres estimés et les informations auxiliaires provenant de la source de données supplémentaire au niveau de l'unité sont utilisés pour produire des prédictions de la variable d'intérêt pour chaque unité dans chaque domaine d'estimation.
- Les valeurs prédites sont ensuite utilisées pour estimer le paramètre d'intérêt au niveau de domaine requis.

Modèles au niveau de l'unité : extensions aux indicateurs non linéaires (2)

Si le **modèle BHF au niveau de l'unité** ne nécessite que le recours à des informations auxiliaires, l'ELL et l'EBP nécessitent des informations auxiliaires pour toutes les unités dans tous les domaines. Par conséquent, la plus grande flexibilité des indicateurs possibles s'accompagne d'exigences plus strictes en matière de données.

Méthode	AVANTAGES	INCONVÉNIENTS
ELL	- Permet d'estimer tout indicateur exprimé comme fonction de la variable d'intérêt - Plus exact en présence d'un grand nombre de domaines et de domaines non échantillonnés	- Présume de l'homogénéité dans les petits domaines - Les résultats peuvent être affectés par des valeurs aberrantes individuelles
EBP	- Permet d'estimer tout indicateur exprimé comme fonction de la variable d'intérêt - Meilleure performance par rapport à ELL concernant l'EQM, en cas de grande hétérogénéité entre les domaines	- Le plan d'échantillonnage n'est pas pris en compte - Les résultats peuvent être affectés par des valeurs aberrantes individuelles ou par une absence de normalité - Présume de l'homogénéité dans les clusters

Merci !

